Πανεπιστήμιο Πειραιώς, Τμήμα Πληροφορικής
Προπτυχιακό Πρόγραμμα Σπουδών
Ακαδ. έτος 2025-26 (εαρινό εξάμηνο)

ΑΝΑΛΥΤΙΚΗ ΔΕΔΟΜΕΝΩΝ

Απαλλακτική Εργασία (ομάδες των 1-2 ατόμων)

Π23062 – ΠΕΡΙΚΛΗΣ ΚΑΝΑΚΗΣ – perikanakis18@yahoo.com

Π23007 – ΑΡΙΣΤΟΤΕΛΗΣ ΑΝΤΩΝΟΠΟΥΛΟΣ – telhs99@hotmail.com

Περιεχόμενα

ΑΠΑΛΛΑΚΤΙΚΉ ΕΡΓΑΣΊΑ (ΟΜΆΔΕΣ ΤΩΝ 1-2 ΑΤΟΜΩΝ) 0

ΤΕΧΝΙΚΉ ΑΝΑΦΟΡΆ: HOUSE PRICES 2

Στοχος και συνολο δεδομενων 2

1. DATA PREPROCESSING 3

1.1 Αναγνωση και αρχικος ελεγχος 3
1.2 Κατηγορικες ελλειψεις 3
1.3 Συμπληρωση αριθμητικων τιμων 5
1.4 LotFrontage ανα γειτονια 5
1.5 Ακραιες τιμες και κατανομες 6
1.6 Συσχετισεις και επιλογη χαρακτηριστικων 7
1.7 Encoding και scaling 7
1.8 Τελικος ελεγχος και αποθηκευση 7

2. CLUSTERING 8

2.1 Στοχος, χαρακτηριστικα και αποσταση 8
2.2 K-Means και επιλογη του k 8
2.3 DBSCAN και δοκιμές παραμέτρων 9
2.4 Όρια της αναζητησης παραμετρων 9
2.5 Οπτικη συγκριση των ομαδων 10
2.6 Συγκριση επιδοσεων και χρονων 11

3. CLASSIFICATION 11

3.1 Στοχος και προετοιμασια δεδομενων 11
3.2 Μοντελα και αξιολογηση 11

4. REGRESSION 12

4.1 Στοχος, δεδομενα και μοναδες 12
4.2 Νευρωνικο δικτυο απο την αρχη 13
4.3 Transfer learning 13
4.4 Αποτελεσματα και συμπερασματα 13

5. ΣΥΝΟΛΙΚΉ ΣΥΝΟΨΗ ΤΩΝ ΕΥΡΗΜΆΤΩΝ 14

ΤΕΧΝΙΚΗ ΑΝΑΦΟΡΑ: HOUSE PRICES

Η παρούσα αναφορά καλύπτει τα τέσσερα στάδια της εργασίας: την προπαρασκευή των δεδομένων, τη συσταδοποίηση, την ταξινόμηση και την παλινδρόμηση. Βασίζεται στον κώδικα και στα αποθηκευμένα αποτελέσματα των αντίστοιχων notebooks.

Στόχος και σύνολο δεδομένων

Εργαζόμαστε με το σύνολο δεδομένων House Prices - Advanced Regression Techniques. Κάθε γραμμή περιγράφει μία κατοικία, με στοιχεία για το οικόπεδο, τους χώρους, τα υλικά, την ποιότητα και τον χρόνο κατασκευής. Η SalePrice είναι η τιμή πώλησης και υπάρχει μόνο στο training set. Στο clustering αναζητούμε ομάδες κατοικιών από τα φυσικά χαρακτηριστικά τους, χωρίς να χρησιμοποιούμε την τιμή πώλησης.

Πίνακας 1. Αρχικές διαστάσεις των δεδομένων.

Σύνολο	**Κατοικίες**	**Στήλες**	**SalePrice**
Train	1.460	81	Ναι
Test	1.459	80	Όχι

Το train περιλαμβάνει το Id, 79 περιγραφικά χαρακτηριστικά και τη SalePrice. Αρχικά εντοπίζονται 43 στήλες κειμένου και 38 αριθμητικές, μαζί με το Id και τη SalePrice. Το MSSubClass μετατρέπεται στη συνέχεια σε κατηγορική μεταβλητή, επειδή οι αριθμοί του είναι κωδικοί τύπων κατοικίας και όχι μετρήσεις.

Ακολουθεί πρώτα η αιτιολόγηση των επιλογών καθαρισμού και μετασχηματισμού, έπειτα η σύγκριση K-Means και DBSCAN και τέλος η ταξινόμηση και η παλινδρόμηση. Οι αριθμητικές επιδόσεις και οι χρόνοι προέρχονται από τις αποθηκευμένες εκτελέσεις των notebooks, ενώ τα γραφήματα έχουν ενσωματωθεί από τα ίδια αρχεία.

1. DATA PREPROCESSING

1.1 Ανάγνωση και αρχικός έλεγχος

Διαβάζουμε τα αρχεία train.csv και test.csv με pandas. Χρησιμοποιούμε keep_default_na=False και δηλώνουμε ως κενά τα «NA» και τα άδεια πεδία. Με αυτόν τον τρόπο η κατηγορία «None», που για ορισμένα χαρακτηριστικά σημαίνει απουσία μιας εγκατάστασης, δεν χάνεται κατά την ανάγνωση. Δημιουργούμε αντίγραφα των δεδομένων για τις αλλαγές του preprocessing.

Εξετάζουμε τους τύπους των στηλών, τα περιγραφικά στατιστικά και το πλήθος των ελλείψεων. Τα μεγάλα ποσοστά κενών δεν οδηγούν αυτόματα σε αφαίρεση μιας στήλης. Για παράδειγμα, η έλλειψη ποιότητας πισίνας μπορεί να συνδέεται με κατοικία χωρίς πισίνα και να έχει διαφορετική σημασία από μια άγνωστη τιμή.

Πίνακας 2. Ενδεικτικές ελλείψεις στο αρχικό train.

Χαρακτηριστικό	**Κενές τιμές**	**Ποσοστό**
PoolQC	1.453	99,52%
MiscFeature	1.406	96,30%
Alley	1.369	93,77%
Fence	1.179	80,75%
FireplaceQu	690	47,26%
LotFrontage	259	17,74%
GarageYrBlt	81	5,55%
MasVnrType / MasVnrArea	8 ανά στήλη	0,55%
Electrical	1	0,07%

1.2 Κατηγορικές ελλείψεις

Για το υπόγειο και το garage ελέγχουμε συνδυαστικά τις επιφάνειες και τις διαθέσιμες περιγραφές. Αν υπάρχουν ενδείξεις ότι η εγκατάσταση υπάρχει αλλά λείπει μια περιγραφή, χρησιμοποιούμε «Unknown». Αν δεν υπάρχει σχετική ένδειξη, χρησιμοποιούμε «None». Αντίστοιχα, για PoolQC, FireplaceQu και MasVnrType αξιοποιούμε τις μεταβλητές PoolArea, Fireplaces και MasVnrArea.

Στις Alley, Fence και MiscFeature τα κενά συμπληρώνονται με «None». Στην Electrical και σε άλλες κατηγορικές στήλες με λίγες ελλείψεις, όπως MSZoning, KitchenQual και SaleType, χρησιμοποιούμε τη συχνότερη κατηγορία του train. Η ίδια τιμή εφαρμόζεται στο test, ώστε ο κανόνας συμπλήρωσης να βασίζεται στα δεδομένα εκπαίδευσης.

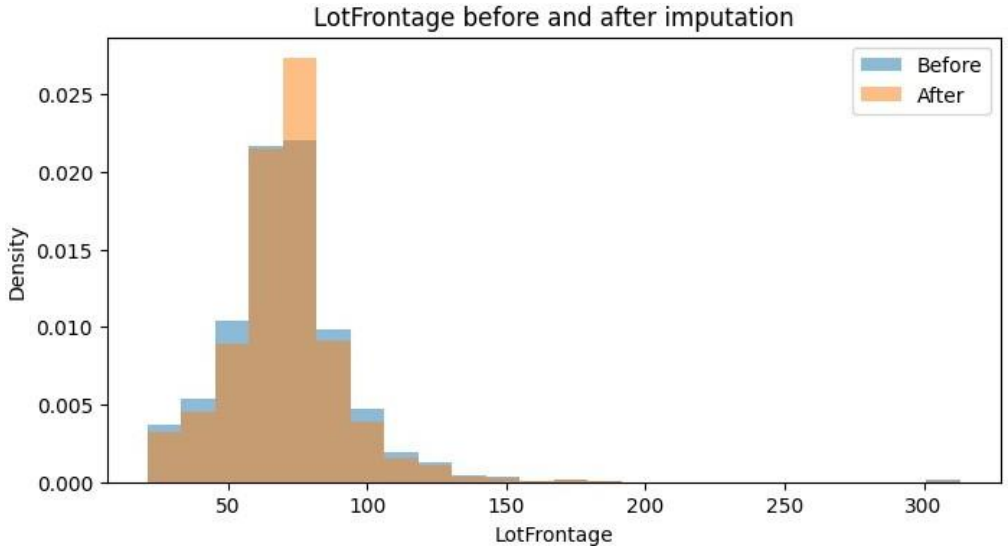
1.3 Συμπλήρωση αριθμητικών τιμών

Για αριθμητικά χαρακτηριστικά υπογείου και garage συμπληρώνουμε με μηδέν τις ελλείψεις όταν έχει καταγραφεί απουσία της αντίστοιχης εγκατάστασης. Τα υπόλοιπα κενά συμπληρώνονται με διαμέσους του train. Στις GarageArea, GarageCars και MasVnrArea ο υπολογισμός αυτής της διαμέσου γίνεται μόνο στις θετικές τιμές.

Στο GarageYrBlt οι μη θετικές τιμές και τα έτη που ξεπερνούν το YrSold θεωρούνται μη έγκυρα και μετατρέπονται σε κενά. Ακολουθεί συμπλήρωση με τη διάμεσο και περιορισμός ώστε το έτος garage να μην ξεπερνά το έτος πώλησης. Στον υπάρχοντα κώδικα η συμπλήρωση εφαρμόζεται και στις κατοικίες χωρίς garage, οπότε η τελική τιμή δεν πρέπει να ερμηνεύεται ως πραγματικό έτος για αυτές τις περιπτώσεις.

1.4 LotFrontage ανά γειτονιά

Για το LotFrontage επιλέγουμε τη διάμεσο της αντίστοιχης Neighborhood. Οι διάμεσοι διαφέρουν αρκετά: από 21 στις BrDale και MeadowV έως 91 στη NoRidge. Έτσι χρησιμοποιούμε πληροφορία από την περιοχή αντί για μία κοινή τιμή για όλες τις κατοικίες. Αν δεν υπάρχει διαθέσιμη διάμεσος γειτονιάς, χρησιμοποιείται η συνολική διάμεσος του train.



Σχήμα 1. Κατανομή του LotFrontage πριν και μετά τη συμπλήρωση. Η σύγκριση γίνεται με κοινά διαστήματα και πυκνότητες.

Για την παρουσίαση του διαγράμματος χρησιμοποιήθηκε βοήθεια από εργαλείο AI.

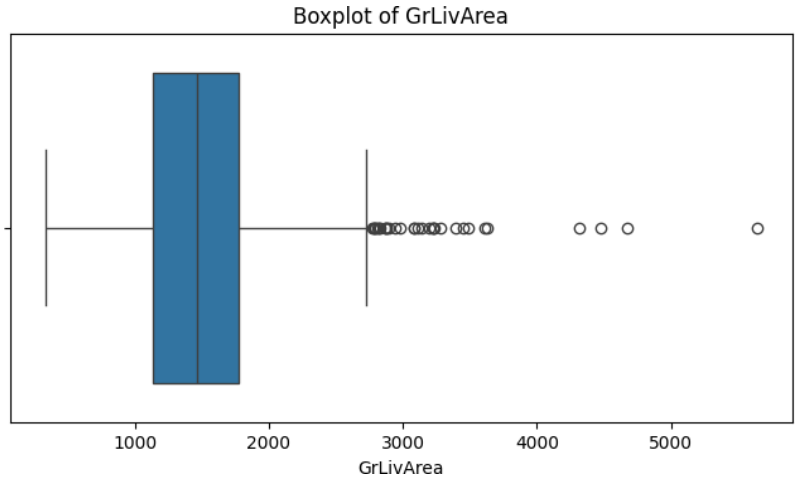
Πίνακας 3. Έλεγχος της συμπλήρωσης του LotFrontage.

Στατιστικό	**Πριν**	**Μετά**
Πλήθος τιμών	1.201	1.460
Μέση τιμή	70,05	70,20
Τυπική απόκλιση	24,28	22,43
Διάμεσος	69,00	70,00

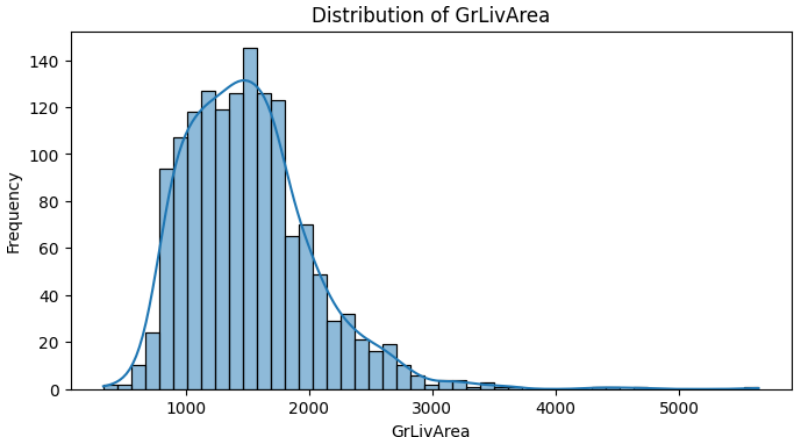
Η μέση τιμή και η διάμεσος μεταβάλλονται λίγο, ενώ η διασπορά μειώνεται. Αυτό είναι αναμενόμενο όταν προσθέτουμε τιμές κοντά στο κέντρο της κάθε γειτονιάς. Ο έλεγχος δείχνει πώς επηρέασε η συμπλήρωση την κατανομή, χωρίς να αποδεικνύει ότι ανακτήθηκαν οι πραγματικές άγνωστες τιμές.

1.5 Ακραίες τιμές και κατανομές

Εξετάζουμε τις αριθμητικές μεταβλητές με box plots και ιστογράμματα. Παράλληλα, χρησιμοποιούμε τον κανόνα IQR: τιμές μικρότερες από Q1 - 1,5 × IQR ή μεγαλύτερες από Q3 + 1,5 × IQR σημειώνονται ως πιθανά outliers. Ο κανόνας λειτουργεί ως ένδειξη για διερεύνηση και όχι ως αυτόματη απόφαση διαγραφής.



Σχήμα 2. Box plot του GrLivArea. Διακρίνονται κατοικίες με ιδιαίτερα μεγάλο κατοικήσιμο χώρο.



Σχήμα 3. Ιστόγραμμα του GrLivArea. Η κατανομή εμφανίζει δεξιά ουρά και λίγες πολύ μεγάλες τιμές.

Για την παρουσίαση των διαγραμμάτων χρησιμοποιήθηκε βοήθεια από εργαλείο AI.

Πίνακας 4. Πιθανά outliers με βάση τον κανόνα IQR.

Χαρακτηριστικό	**Πλήθος**	**Ποσοστό**
LotArea	69	4,73%
TotalBsmtSF	61	4,18%
GrLivArea	31	2,12%
GarageArea	21	1,44%

Διατηρούμε τις παρατηρήσεις, επειδή οι μεγάλες επιφάνειες μπορεί να αντιστοιχούν σε πραγματικές κατοικίες. Επίσης, σε μεταβλητές με πολλά μηδενικά ο IQR μπορεί να χαρακτηρίζει υπαρκτά χαρακτηριστικά ως ακραία. Η επιλογή αυτή διατηρεί την πληροφορία, αλλά αφήνει τις πολύ μεγάλες τιμές να επηρεάζουν τις αποστάσεις και τα κέντρα στο clustering.

1.6 Συσχετίσεις και επιλογή χαρακτηριστικών

Υπολογίζουμε τον συντελεστή Pearson για τις αριθμητικές μεταβλητές και εξετάζουμε ζεύγη με απόλυτη συσχέτιση τουλάχιστον 0,70. Ο πίνακας παρουσιάζει ενδεικτικά ζεύγη από το αποθηκευμένο αποτέλεσμα, χωρίς τη διπλή εμφάνιση της ίδιας σχέσης.

Πίνακας 5. Ενδεικτικές ισχυρές συσχετίσεις.

Ζεύγος χαρακτηριστικών	**Pearson r**
GarageCars - GarageArea	0,8825
GrLivArea - TotRmsAbvGrd	0,8255
TotalBsmtSF - 1stFlrSF	0,8195
YearBuilt - GarageYrBlt	0,7772
OverallQual - SalePrice	0,7910
GrLivArea - SalePrice	0,7086

Δεν αφαιρούμε χαρακτηριστικά λόγω συσχέτισης και δεν εφαρμόζουμε PCA. Για παράδειγμα, η χωρητικότητα ενός garage και η επιφάνειά του σχετίζονται, αλλά περιγράφουν διαφορετικά στοιχεία. Οι σχέσεις με τη SalePrice δείχνουν συσχέτιση και όχι αιτιότητα ή μετρημένη προγνωστική επίδοση. Στο clustering επιλέγεται ξεχωριστά ένα σύνολο τεσσάρων χαρακτηριστικών.

1.7 Encoding και scaling

Μετατρέπουμε τις κατηγορικές μεταβλητές με One-Hot Encoding, χωρίς αφαίρεση της πρώτης κατηγορίας. Οι διαθέσιμες κατηγορίες προκύπτουν από το train και προσθέτουμε την «Unknown» για νέες τιμές του test. Έπειτα ευθυγραμμίζουμε τις στήλες των δύο συνόλων. Η SalePrice αφαιρείται από το test μετά την ευθυγράμμιση.

Στα αριθμητικά χαρακτηριστικά εφαρμόζουμε StandardScaler: αφαιρούμε τη μέση τιμή του train και διαιρούμε με την τυπική του απόκλιση. Στο test εφαρμόζονται οι ίδιες παράμετροι. Η SalePrice και το Id δεν γίνονται scale. Δεν χρησιμοποιείται λογαριθμικός μετασχηματισμός, συνεπώς η τυποποίηση δεν αφαιρεί την ασυμμετρία ή τα outliers.

1.8 Τελικός έλεγχος και αποθήκευση

Πίνακας 6. Τελικές διαστάσεις και έλεγχος ελλείψεων.

Σύνολο	**Γραμμές**	**Στήλες**	**Κενά**
Train processed	1.460	362	0
Test processed	1.459	361	0

Οι στήλες συμφωνούν όταν εξαιρεθεί η SalePrice από το train. Το Id παραμένει στα αποθηκευμένα αρχεία, αλλά δεν επιλέγεται για το clustering. Τα αρχεία αποθηκεύονται στον φάκελο data/processed. Οι παραπάνω έλεγχοι επιβεβαιώνουν τη δομή και την απουσία κενών, όχι τη συνολική καταλληλότητα των δεδομένων για κάθε μελλοντικό μοντέλο.

2. CLUSTERING

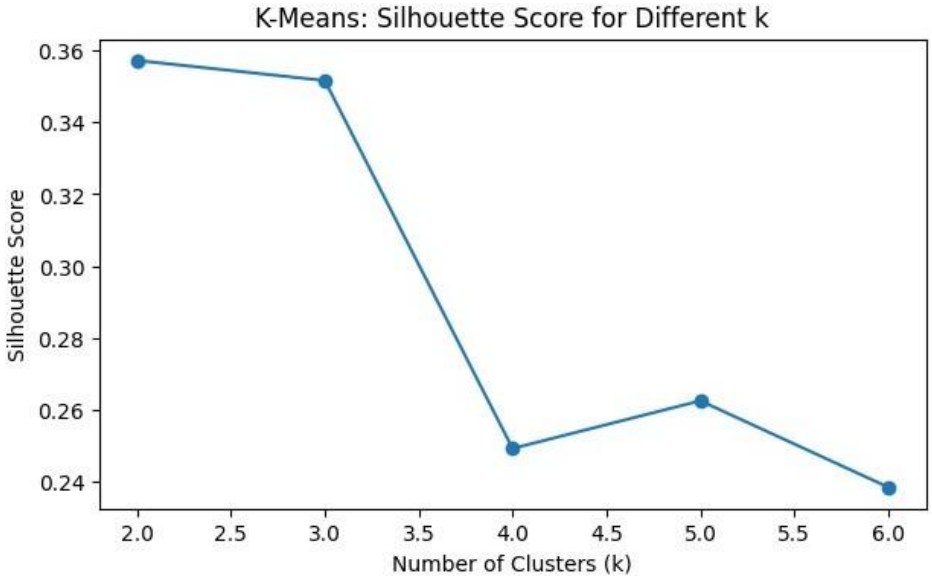
2.1 Στόχος, χαρακτηριστικά και απόσταση

Αναζητούμε ομάδες κατοικιών που μοιάζουν ως προς το μέγεθος και τη δομή τους. Χρησιμοποιούμε τις GrLivArea, GarageArea, TotalBsmtSF και LotArea από το processed train, δηλαδή 1.460 κατοικίες με τέσσερα τυποποιημένα χαρακτηριστικά. Η SalePrice δεν συμμετέχει στη δημιουργία των ομάδων.

Χρησιμοποιούμε ευκλείδεια απόσταση. Το scaling επιτρέπει να συγκρίνουμε τις διαστάσεις χωρίς να επικρατεί μία μεταβλητή μόνο λόγω της αρχικής μονάδας ή κλίμακάς της. Παρόλα αυτά, οι ακραίες παρατηρήσεις παραμένουν και μπορούν να επηρεάσουν το αποτέλεσμα.

2.2 K-Means και επιλογή του k

Δοκιμάζουμε k από 2 έως 6, με random_state=42 και n_init=10. Για κάθε τιμή υπολογίζουμε Silhouette Score. Μεγαλύτερη τιμή δείχνει ότι τα σημεία είναι, κατά μέσο όρο, πιο κοντά στην ομάδα τους από ό,τι στην κοντινότερη άλλη ομάδα.



Σχήμα 4. Silhouette Score για τις πέντε τιμές του k που δοκιμάστηκαν.

Για την παρουσίαση του διαγράμματος χρησιμοποιήθηκε βοήθεια από εργαλείο AI.

Πίνακας 7. Αποτελέσματα K-Means.

k	**2**	**3**	**4**	**5**	**6**
Silhouette	0,3572	0,3516	0,2492	0,2625	0,2385

Επιλέγουμε k=2, επειδή δίνει το υψηλότερο score από τις συγκεκριμένες δοκιμές. Η διαφορά από το k=3 είναι μικρή, περίπου 0,0056, άρα η επιλογή δεν σημαίνει ότι τεκμηριώθηκαν δύο απόλυτα διακριτοί φυσικοί τύποι κατοικιών. Οι τελικές ομάδες περιλαμβάνουν 466 και 994 κατοικίες. Οι αριθμοί των ετικετών απλώς διακρίνουν τις ομάδες και δεν εκφράζουν κατάταξη. Οι τιμές του γραφήματος προέρχονται από την αποθηκευμένη εκτέλεση του notebook.

2.3 DBSCAN και δοκιμές παραμέτρων

Ο DBSCAN σχηματίζει ομάδες από πυκνές περιοχές και μπορεί να αφήσει σημεία ως noise, με ετικέτα -1. Το eps ορίζει την ακτίνα της γειτονιάς, ενώ το min_samples το ελάχιστο πλήθος σημείων μέσα σε αυτή, μαζί με το ίδιο το σημείο, για να θεωρηθεί σημείο πυρήνα.

Ξεκινάμε με eps=0,5 και min_samples=5: προκύπτουν 175 noise points και score 0,0363. Έπειτα μεταβάλλουμε το eps, κρατώντας min_samples=5. Το Silhouette Score υπολογίζεται μόνο στις κατοικίες που εντάχθηκαν σε clusters.

Πίνακας 8. Μεταβολή του eps με min_samples=5.

eps	**Silhouette**	**Noise**	**Noise (%)**
0,3	-0,1242	516	35,34%
0,5	0,0363	175	11,99%
0,7	0,2291	89	6,10%
1,0	Δεν υπολογίστηκε	39	2,67%

Για eps=1,0 ο κώδικας αποθηκεύει -1 ως ένδειξη μη υπολογισμού, επειδή δεν υπάρχουν τουλάχιστον δύο clusters μετά την εξαίρεση του noise. Δεν πρόκειται για μετρημένο score. Αντίθετα, το αρνητικό score για eps=0,3 είναι πραγματικό αποτέλεσμα και δείχνει προβληματικό διαχωρισμό με βάση τη συγκεκριμένη μετρική.

Πίνακας 9. Μεταβολή του min_samples με eps=0,7.

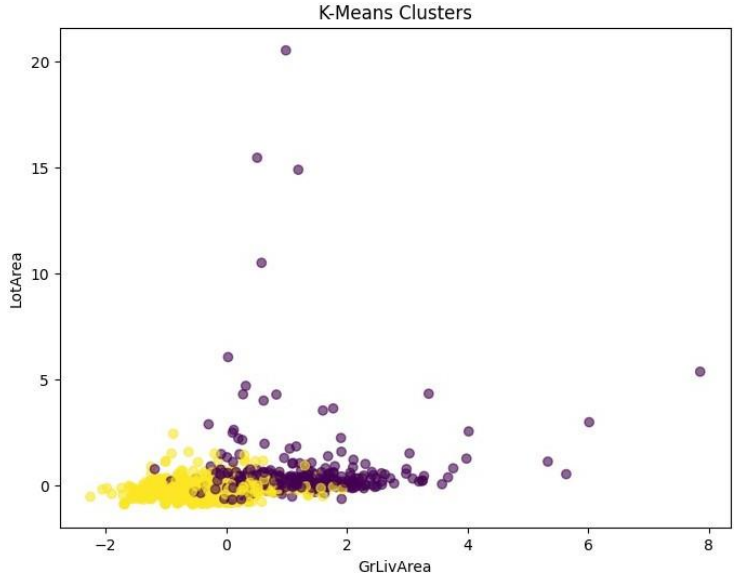
min_samples	**Silhouette**	**Noise**	**Noise (%)**
3	0,1166	71	4,86%
5	0,2291	89	6,10%
10	0,2674	117	8,01%
15	0,2723	140	9,59%

Επιλέγουμε eps=0,7 και min_samples=15 από τις δοκιμές μας. Προκύπτουν τρία clusters και 140 noise points. Το score αυξάνεται, αλλά ταυτόχρονα περισσότερες κατοικίες εξαιρούνται από τον υπολογισμό του. Επομένως, το score εξετάζεται μαζί με την κάλυψη των δεδομένων και δεν αποτελεί το μοναδικό κριτήριο.

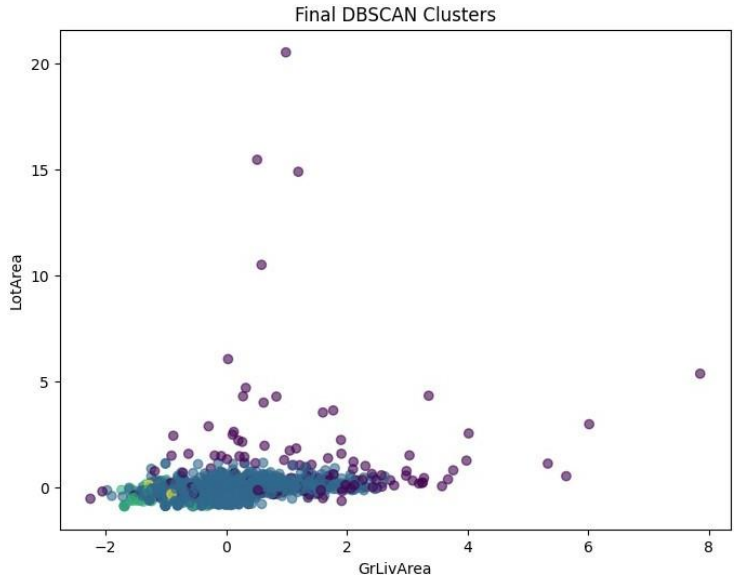
2.4 Όρια της αναζήτησης παραμέτρων

Οι παράμετροι εξετάστηκαν διαδοχικά: πρώτα το eps με σταθερό min_samples και μετά το min_samples με σταθερό eps. Δεν δοκιμάστηκαν όλοι οι δυνατοί συνδυασμοί. Τα αποτελέσματα αφορούν τις συγκεκριμένες ρυθμίσεις και τα τέσσερα επιλεγμένα χαρακτηριστικά, ενώ διαφορετική επιλογή ή μετασχηματισμός τους μπορεί να αλλάξει τις ομάδες.

2.5 Οπτική σύγκριση των ομάδων



Σχήμα 5. Οι ομάδες του K-Means στις τυποποιημένες GrLivArea και LotArea.



Σχήμα 6. Απεικόνιση του τελικού DBSCAN. Η ετικέτα -1 αντιστοιχεί σε noise και δεν είναι επιπλέον cluster.

Για την παρουσίαση των διαγραμμάτων χρησιμοποιήθηκε βοήθεια από εργαλείο AI.

Τα διαγράμματα δείχνουν τις ίδιες δύο διαστάσεις, ενώ οι αλγόριθμοι χρησιμοποίησαν τέσσερις. Σημεία που φαίνονται κοντινά μπορεί να διαφέρουν στο GarageArea ή στο TotalBsmtSF. Έτσι, η επικάλυψη στο γράφημα δεν περιγράφει πλήρως τον διαχωρισμό στον χώρο των χαρακτηριστικών.

Ο K-Means αναθέτει κάθε κατοικία σε μία από τις δύο ομάδες. Ο DBSCAN δίνει διαφορετική εικόνα, καθώς ορισμένα σημεία δεν εντάσσονται σε ομάδες. Δεν αποδίδουμε ονομασίες όπως «ακριβές» ή «φθηνές» κατοικίες: η SalePrice δεν χρησιμοποιήθηκε και δεν έχει πραγματοποιηθεί ανάλυση τιμών ανά cluster. Τα διαγράμματα προέρχονται από τα αποθηκευμένα αποτελέσματα του notebook.

2.6 Σύγκριση επιδόσεων και χρόνων

Πίνακας 10. Σύγκριση τελικών μοντέλων από την αποθηκευμένη εκτέλεση.

Κριτήριο	**K-Means**	**DBSCAN**
Ρυθμίσεις	k=2, n_init=10	eps=0,7, min_samples=15
Clusters	2	3
Noise points	0	140
Σημεία στο score	1.460	1.320
Silhouette Score	0,3572	0,2723
Χρόνος fit (s)	0,1741	0,0643

Ο K-Means έχει μεγαλύτερο score, αλλά οι τιμές αφορούν διαφορετικό σύνολο κατοικιών. Ο DBSCAN είναι ταχύτερος σε αυτή τη μέτρηση. Οι χρόνοι αφορούν μία εκτέλεση, χωρίς αναζήτηση παραμέτρων και υπολογισμό του score, και δεν τεκμηριώνουν γενική υπεροχή ταχύτητας.

Στον K-Means επιλέγουμε κυρίως το k. Στον DBSCAN συνδυάζουμε eps και min_samples και αξιολογούμε το noise. Η δυνατότητα να μένουν κατοικίες εκτός ομάδων είναι χρήσιμη, χωρίς να σημαίνει ότι οι κατοικίες αυτές έχουν λανθασμένα δεδομένα.

3. CLASSIFICATION

3.1 Στόχος και προετοιμασία δεδομένων

Στην ταξινόμηση προσπαθούμε να προβλέψουμε το HouseStyle, δηλαδή τον τύπο της κατοικίας, από φυσικά και δομικά χαρακτηριστικά της. Χρησιμοποιούμε τα GrLivArea, 1stFlrSF, 2ndFlrSF, TotalBsmtSF, GarageArea, LotArea, TotRmsAbvGrd, FullBath, HalfBath και YearBuilt. Δεν χρησιμοποιούμε το Id, την τιμή SalePrice ή το MSSubClass, που σχετίζεται άμεσα με τον τύπο της κατοικίας. Το HouseStyle χρησιμοποιείται μόνο ως στόχος και έχει οκτώ κατηγορίες.

Ξεκινάμε από το αρχικό train.csv, επειδή περιέχει τον στόχο. Στα δέκα χαρακτηριστικά δεν υπάρχουν κενές τιμές. Χωρίζουμε τις 1.460 κατοικίες σε 1.168 για εκπαίδευση και 292 για τελικό έλεγχο, διατηρώντας περίπου την αναλογία των κατηγοριών με stratify και σταθερό random_state=42. Εφαρμόζουμε StandardScaler, τον οποίο προσαρμόζουμε μόνο στο τμήμα εκπαίδευσης. Έτσι, το test δεν επηρεάζει τον μετασχηματισμό των δεδομένων.

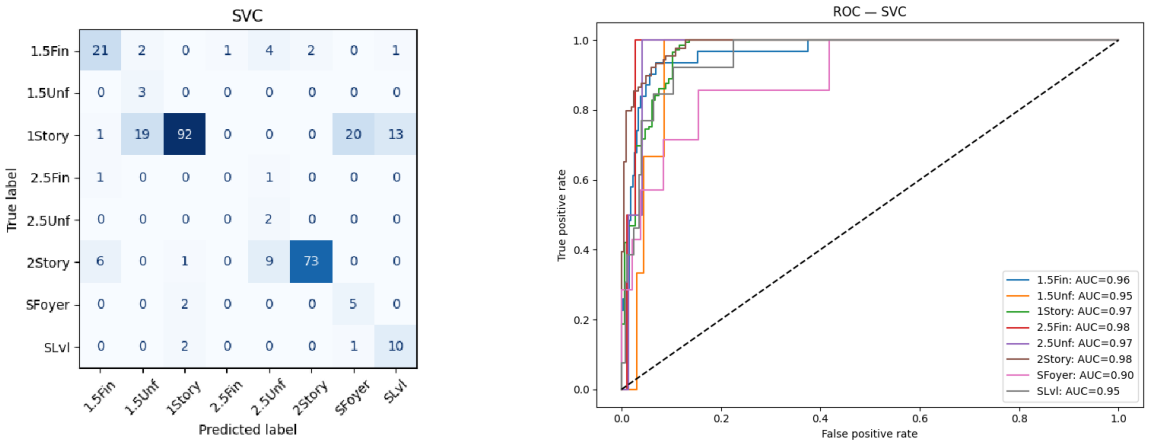
3.2 Μοντέλα και αξιολόγηση

Δοκιμάζουμε δύο ταξινομητές της scikit-learn: Gaussian Naive Bayes και SVC. Ο πρώτος είναι ένα απλό πιθανοτικό μοντέλο. Στον SVC χρησιμοποιούμε πυρήνα RBF, C=1 και gamma="scale". Με class_weight="balanced" δίνουμε μεγαλύτερο βάρος στις σπάνιες κατηγορίες. Ενεργοποιούμε επίσης τον υπολογισμό πιθανοτήτων για τις καμπύλες ROC. Εκπαιδεύουμε και συγκρίνουμε τα δύο μοντέλα στο ίδιο σύνολο δεδομένων.

Η accuracy δείχνει το ποσοστό των σωστών προβλέψεων. Η precision δείχνει πόσες προβλέψεις μιας κατηγορίας είναι σωστές, ενώ η recall πόσα από τα πραγματικά δείγματά της εντοπίζονται. Το F1 συνδυάζει precision και recall. Χρησιμοποιούμε macro μέσο όρο, ώστε κάθε κατηγορία να έχει ίση βαρύτητα, επειδή οι κατηγορίες δεν έχουν το ίδιο πλήθος κατοικιών.

Πίνακας 11. Αποτελέσματα ταξινόμησης στο σύνολο ελέγχου.

Μετρική	**Naive Bayes**	**SVC**
Accuracy	0,6336	0,7055
Precision (macro)	0,3504	0,4381
Recall (macro)	0,5028	0,7020
F1 (macro)	0,3548	0,4548



Σχήμα 7. Πίνακας σύγχυσης του SVC (πάνω) και καμπύλες ROC ανά κατηγορία (κάτω).

Για την παρουσίαση των διαγραμμάτων χρησιμοποιήθηκε βοήθεια από εργαλείο AI.

Ο SVC πετυχαίνει καλύτερη επίδοση και στις τέσσερις μετρικές. Ο πίνακας σύγχυσης δείχνει ποιες κατηγορίες μπερδεύονται: για παράδειγμα, βρίσκει σωστά 5 από τις 7 κατοικίες SFoyer και 10 από τις 13 SLvl, αλλά καμία από τις δύο 2.5Fin. Οι ROC εξετάζουν κάθε κατηγορία απέναντι σε όλες τις άλλες και δείχνουν πόσο καλά τη διαχωρίζουν οι πιθανότητες. Υψηλό AUC δεν σημαίνει απαραίτητα σωστή τελική κατηγορία. Τα πολύ μικρά πλήθη ορισμένων κατηγοριών περιορίζουν την ασφάλεια των συμπερασμάτων μας.

4. Regression

4.1 Στόχος, δεδομένα και μονάδες

Στην παλινδρόμηση προβλέπουμε την τιμή πώλησης SalePrice. Χρησιμοποιούμε τα δέκα χαρακτηριστικά της ταξινόμησης και επιπλέον τα OverallQual, OverallCond, YearRemodAdd και GarageCars, δηλαδή 14 εισόδους συνολικά. Ξεκινάμε πάλι από το αρχικό train.csv και δεν υπάρχουν κενά σε αυτές τις εισόδους. Το HouseStyle δεν μπαίνει στις εισόδους της παλινδρόμησης· χρησιμοποιείται για τον διαχωρισμό των δεδομένων και ως στόχος στην προεκπαίδευση.

Χωρίζουμε τα δεδομένα σε 876 κατοικίες για εκπαίδευση, 292 για validation και 292 για τελικό test, με σταθερό random_state=42 και stratify ως προς το HouseStyle. Το validation μάς βοηθά να παρακολουθούμε την εκπαίδευση, ενώ το test χρησιμοποιείται στην τελική αξιολόγηση. Ο StandardScaler μαθαίνει μόνο από το train. Μετατρέπουμε τις αρχικές τιμές από δολάρια σε ευρώ με τη σταθερή

ενδεικτική ισοτιμία 1 δολάριο = 0,90 ευρώ. Για την εκπαίδευση διαιρούμε τον στόχο με 90.000 και επαναφέρουμε τις προβλέψεις σε ευρώ πριν υπολογίσουμε τα σφάλματα.

4.2 Νευρωνικό δίκτυο από την αρχή

Κατασκευάζουμε ένα νευρωνικό δίκτυο με TensorFlow/Keras. Έχει δύο κρυφά επίπεδα με 64 και 32 νευρώνες και ενεργοποίηση ReLU. Η έξοδος έχει έναν νευρώνα με γραμμική ενεργοποίηση, ώστε να προβλέπει μία αριθμητική τιμή. Χρησιμοποιούμε Adam και απώλεια MSE, έως 200 εποχές και batch size 32. Με EarlyStopping σταματάμε αν το σφάλμα validation δεν βελτιωθεί για 20 εποχές και κρατάμε τα καλύτερα βάρη. Στην αποθηκευμένη εκτέλεση σταμάτησε στις 57 εποχές, με καλύτερη την 37η.

4.3 Transfer learning

Για τη δεύτερη προσέγγιση εκπαιδεύουμε πρώτα ένα δίκτυο με τις ίδιες 14 εισόδους και τα ίδια δύο κρυφά επίπεδα, αλλά με στόχο το HouseStyle. Η έξοδος έχει οκτώ νευρώνες με softmax και χρησιμοποιούμε sparse categorical crossentropy. Η προεκπαίδευση γίνεται έως 120 εποχές, με EarlyStopping 10 εποχών. Δεν χρησιμοποιούμε εξωτερικό έτοιμο μοντέλο: μεταφέρουμε τη γνώση από την ταξινόμηση του τύπου κατοικίας στην πρόβλεψη της τιμής της.

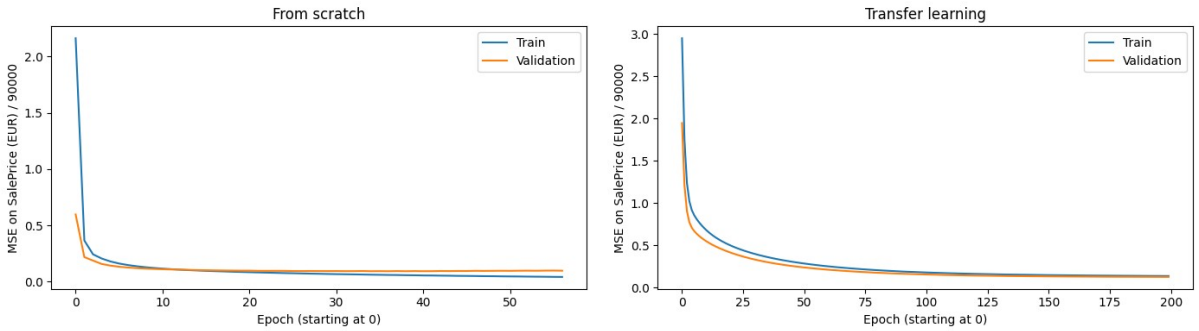
Κρατάμε τα δύο κρυφά επίπεδα και παγώνουμε τα βάρη τους. Αντικαθιστούμε την έξοδο με έναν γραμμικό νευρώνα και εκπαιδεύουμε μόνο αυτή τη νέα έξοδο για το SalePrice. Χρησιμοποιούμε τις ίδιες ρυθμίσεις εκπαίδευσης της παλινδρόμησης και τα ίδια train, validation και test, ώστε η σύγκριση να είναι κοινή. Το τελικό test δεν χρησιμοποιείται ούτε στην προεκπαίδευση ούτε για την επιλογή βαρών.

4.4 Αποτελέσματα και συμπεράσματα

Πίνακας 12. Αποτελέσματα παλινδρόμησης στο κοινό σύνολο ελέγχου.

Μετρική	**Από την αρχή**	**Transfer learning**
MAE (€)	18.746,64	24.500,07
MAPE (%)	12,00	16,42
RMSE (€)	33.142,11	49.834,76

Το MAE εκφράζει το μέσο απόλυτο λάθος σε ευρώ, το MAPE το μέσο απόλυτο ποσοστιαίο λάθος και το RMSE δίνει μεγαλύτερη βαρύτητα στα μεγάλα λάθη. Και στις τρεις μετρικές η μικρότερη τιμή είναι καλύτερη. Το δίκτυο που εκπαιδεύσαμε από την αρχή έχει καλύτερα αποτελέσματα, με μέσο απόλυτο λάθος περίπου 18.747 ευρώ. Το μεγαλύτερο RMSE δείχνει ότι υπάρχουν και ορισμένες αρκετά μεγάλες αποκλίσεις.



Σχήμα 8. Απώλεια εκπαίδευσης και validation: μοντέλο από την αρχή (πάνω), transfer learning (κάτω). Η απώλεια αφορά τον κλιμακωμένο στόχο, όχι ευρώ.

Για την παρουσίαση των διαγραμμάτων χρησιμοποιήθηκε βοήθεια από εργαλείο AI.

Οι καμπύλες δείχνουν πώς αλλάζει το σφάλμα κατά την εκπαίδευση και μας βοηθούν να ελέγξουμε τη διαφορά μεταξύ train και validation. Στο notebook εξετάζουμε επίσης πραγματικές και προβλεπόμενες τιμές. Το transfer learning δεν βελτίωσε την επίδοση: τα παγωμένα χαρακτηριστικά που έμαθαν να ξεχωρίζουν το HouseStyle δεν ήταν αρκετά για καλύτερη εκτίμηση της τιμής. Εμφανίστηκε και μία αρνητική πρόβλεψη, επειδή η γραμμική έξοδος δεν επιβάλλει θετικό αποτέλεσμα. Την κρατάμε στην αξιολόγηση και την αναφέρουμε ως περιορισμό. Τα συμπεράσματα αφορούν τον συγκεκριμένο διαχωρισμό και τις ρυθμίσεις που δοκιμάσαμε.

5. Συνολικη συνοψη των ευρηματων

Στην εργασία εξετάσαμε πώς τα χαρακτηριστικά των κατοικιών συνδέονται με τη δομή, τον τύπο και την τιμή τους. Στο preprocessing συμπληρώσαμε τις ελλείψεις, κωδικοποιήσαμε τις κατηγορίες και εφαρμόσαμε scaling. Τα Σχήματα 1-3 δείχνουν τις κατανομές και τις ακραίες τιμές. Κρατήσαμε τις ακραίες παρατηρήσεις, επειδή μπορεί να αφορούν πραγματικές κατοικίες, αλλά αναγνωρίζουμε ότι επηρεάζουν τα μοντέλα.

Στο clustering βρήκαμε ομάδες με παρόμοιο μέγεθος και δομή. Ο K-Means είχε μεγαλύτερο silhouette score, ενώ ο DBSCAN άφησε ορισμένες κατοικίες ως noise. Η σύγκριση χρειάζεται προσοχή, επειδή τα scores αφορούν διαφορετικά σύνολα σημείων. Τα Σχήματα 5-6 δείχνουν επικάλυψη, άρα οι ομάδες δεν είναι απόλυτα ξεχωριστοί τύποι κατοικιών.

Στο classification ο SVC προέβλεψε καλύτερα το HouseStyle από τον Naive Bayes, με accuracy 70,55%, αλλά δυσκολεύτηκε σε σπάνιες κατηγορίες (Σχήμα 7). Στο regression το δίκτυο από την αρχή είχε μικρότερο σφάλμα από το transfer learning, με MAE περίπου 18.747 ευρώ. Το Σχήμα 8 δείχνει την πορεία της εκπαίδευσης. Συνολικά, τα χαρακτηριστικά δίνουν χρήσιμη πληροφορία, αλλά όχι τέλειες προβλέψεις. Ο σωστός καθαρισμός και διαχωρισμός των δεδομένων είναι σημαντικός, ενώ μια πιο σύνθετη μέθοδος δεν είναι απαραίτητα καλύτερη. Τα συμπεράσματά μας αφορούν τις συγκεκριμένες δοκιμές.